

## Բովանդակություն

Ներածություն.....	3
Գլուխ 1. Գրականության վերլուծական ակնարկ .....	5
1.1 Մեքենայական ուսուցում .....	5
1.1.1 Վերահսկվող ուսուցում.....	5
1.1.2 Չվերահսկվող ուսուցում .....	6
1.1.3 Որոշ նշանակումներ .....	7
1.2 Ուսուցման տարրեր.....	8
1.2.1 Արժեքի ֆունկցիա.....	8
1.2.2 Նվազող գրադիենտ.....	9
1.2.3 Ուսուցման գործակից.....	11
1.2.4 Մուտքային տվյալի հատկության մասշտաբավորում .....	12
1.3 Պոլինոմալ ռեգրեսիա .....	13
1.4 Դասակարգում .....	14
1.4.1 Որոշման սահման .....	16
1.4.2 Լոգիստիկ հիպոթեզի արժեքի ֆունկցիան.....	18
1.4.3 Բազմադաս դասակարգում.....	21
1.5 Նորմալ հավասարում .....	22
1.6 Նեյրոնային ցանցեր.....	23
1.7 Խնդրի դրվածքը.....	25
Գլուխ 2. Գեներատիվ մրցակցող ցանցերի կիրառումը նկարի տեսքով թաքնագրության կրիչ ստեղծելու համար.....	27
1.1 Մրցակցող ցանցեր .....	27
1.1.1 Մինիմալ խաղ.....	27
1.1.2 Գեներատիվ մրցակցող ցանցեր .....	28
1.2 Խորը փաթույթային գեներատիվ մրցակցող ցանցեր.....	30

1.3	Թաքնավերլուծություն մեքենայական ուսուցմամբ .....	30
1.4	Թաքնագրության կրիչի գներացիա .....	32
Գլուխ 3.	Բնապահպանության հարցերի հիմնավորում .....	35
1.5	Էկոլոգիական փորձաքննության նպատակները և խնդիրները .....	35
	Գրականություն .....	41

## Ներածություն

Թաքնագրությունը<sup>[Error! Reference source not found.]</sup> գաղտնի տեղեկատվությունը ոչ գաղտնի տեղեկատվության (կոնտեյներ, կամ կրիչ) մեջ թաքցման մեթոդների հավաքածու է: Իսկ թաքնավերլուծությունը<sup>[Error! Reference source not found.]</sup> (Steganalysis), մի գործընթաց է, որն ուղղված է պարզելուն, թե արդյո՞ք հաղորդագրությունը պարունակում է թաքնված ինֆորմացիա, և հնարավորության դեպքում վերականգնել այն: Թաքնված ինֆորմացիայի ներկայությունը հայտնաբերելու համար սովորաբար օգտագործվում է երկուական դասակարգիչ (Binary classifier): Սույն ուսումնասիրության մեջ ներկայացվելու է մի մոդել, որը ստեղծում է նկարկրիչներ, հիմնված՝ խորը փաթույթային ստեղծարար մրցակցող ցանցերի (Deep Convolutional Generative Adversarial Networks, կրճատ՝ DCGAN)<sup>[Error! Reference source not found..Error! Reference source not found.]</sup> վրա: Այս մոտեցումը թույլ է տալիս ստեղծել ավելի թաքնակայուն կրիչ, ներդրված հաղորդագրությամբ, օգտագործելով ստանդարտ թաքնագրային ալգորիթմներ:

Այս թեմայի շուրջ 2016թ.-ին կատարվել է հետազոտություն<sup>[Error! Reference source not found.]</sup>, որի ընթացքում փորձել են գեներացնել մարդկանց դեմքեր: Մոդելը հաջողությամբ մոլորեցրել է թաքնագրային վերլուծիչին, սակայն որոշ դեպքերում մարդու աչքը գեներացված նկարները հեշտությամբ կարող էր տարբերել իրականից, քանզի մոդելին՝ ուսուցման ժամանակ, տրամադրվել էին տարբեր սեռի մարդկանց դեմքեր, սակայն չէին հաշվի առել այդ հանգամանքը:

Ուսուցմանը մասնակցելու են միանգամից 3 մոդել: Դրանք են՝

1. Գեներացնող մոդել (Գեներատոր - Generator) - G
2. Տարբերակող մոդել (Տարբերակիչ - Discriminator) - D
3. Թաքնավերլուծող մոդել (Թաքնավերլուծիչ - Steganalyser) - S

Առաջին մոդելը՝ գեներատորը, պատասխանատու է նկարներ գեներացնելու համար, այն պետք է այնպիսի նկարներ գեներացնի, որ հնարավոր չլինի տարբերել իրական նկարներից: Այս խնդրի լուծման համար օգտագործվելու է երկրորդ մոդելը՝ տարբերակիչը, որի խնդիրն է լինելու տարբերել իրական նկարը կեղծից (կեղծ են բոլոր այն նկարները որոնք ստեղծել է G գեներատորը): Այս ամենից հետո գործի է անցնում 3-րդ մոդելը՝ վերլուծիչը, որի խնդիրն է պարզել արդյո՞ք տրված նկարում առկա է թաքնագրված ինֆորմացիա, թե՞ ոչ: D վերլուծիչին ուսուցման ընթացքում տրամադրվելու են գեներատորի նկարները, որոնք արդեն

պարունակում են թաքնագրված ինֆորմացիա, ինչպես նաև սովորական նկարներ, որոնք չեն պարունակում ոչ մի թաքնագրված ինֆորմացիա:

Այսպիսով D տարբերակիչն ու S վերլուծիչը բարելավելու են իրենց արդյունքը՝ հիմնվելով G գեներատորի տրամադրած և սովորական նկարների վրա, իսկ G-ն բարելավելու է իր արդյունքը՝ հիմնվելով D-ի և S-ի արդյունքի վրա: Հենց այստեղ էլ առաջ է գալիս մրցակցող ցանցերի գաղափարը, քանզի ստացվում է, որ ցանցերը մրցում են միմյանց հետ, թե ում արդյունքն ավելի լավը կլինի:

Վերջերս մշակված մրցակցող ցանցերը<sup>[Error! Reference source not found.]</sup> հզոր գեներացնող մոդելներ են, որոնց հիմնական գաղափարը գեներատորի և տարբերակիչի ուսուցումն է մինիմալ խաղի<sup>[Error! Reference source not found.]</sup> միջոցով: G մոդելը մուտքին ստանում է պատահական՝ այսպես ասած անիմաստ նկար, որի հիման վրա փորձում է ստեղծել հնարավորինս իրականին մոտ պատկեր, իսկ D-ն ձգտում է տարբերակել իրական պատկերները կեղծերից:

Գոյություն ունեն նմանատիպ ցանցերի տարբեր ձևափոխություններ՝

- Խորը փաթույթային ստեղծարար մրցակցող ցանցեր<sup>[Error! Reference source not found.]</sup>
  - այս մոդելը ստեղծարար մրցակցող ցանցի (GAN) փոփոխություն է, որը մասնագիտացված է պատկերների առաջացման ուղղությամբ
- Պայմանական մրցակցող ցանցեր<sup>[Error! Reference source not found.]</sup>
  - թույլ է տալիս ստեղծել որևէ դասի օբյեկտներ
- Պատկերների առաջացում հիմնված տեքստային նկարագրության վրա<sup>[Error! Reference source not found.]</sup>.

Թաքնագրվող գաղտնի ինֆորմացիան, ինչպես նաև կրիչը, կարող է ներկայացված լինել տարբեր տեսքով՝ նկարի, տեքստի, տեսահոլովակի, ձայնագրության և այլն: Այս ուսումնասիրության մեջ կատարվելու է տեքստի թաքնագրում նկարում և օգտագործվելու է DCGAN տեսակը:

# Գլուխ 1. Գրականության վերլուծական ակնարկ

## 1.1 Մեքենայական ուսուցում

Նախքան անցնելը բուն թեմային, ծանոթանանք մեքենայական ուսուցման (Machine Learning<sup>[9]</sup>, կրճատ՝ ML) հետ: Արթուր Սամուելն այն նկարագրում է այսպես «մեքենայական ուսուցումը մի տեխնոլոգիա է, որը համակարգիչներին հնարավորություն է տալիս սովորելու, առանց բացահայտ ծրագրավորված լինելու»: Սա, իհարկե, ոչ պաշտոնական ձևակերպում է, սակայն լավ պատկերացում է տալիս:

Մեքենայական ուսուցման խնդիրներից են.

- Վերահսկվող ուսուցում (Supervised learning)
- Չվերահսկվող ուսուցում (Unsupervised learning)
  - Սրա մասնավոր դեպք է խորհրդատու համակարգը (Recommender system)
- Ուսուցում ամրապնդմամբ (Reinforcement learning)

Վերահսկվող ուսուցման դեպքում մեքենային տրվում է մուտքային տվյալների հավաքածու և այդ տվյալներին համապատասխան ելքային արժեքները: Այսպիսով այս ուսուցման դեպքում մեքենային հայտնի են ամեն մի մուտքային ինֆորմացիային համապատասխանող ելքային արժեքը կամ արժեքները:

### 1.1.1 Վերահսկվող ուսուցում

Վերահսկվող ուսուցման (Supervised Learning) խնդիրները դասակարգվում են հետևյալ 2 տիպերի.

- Ռեգրեսիայի խնդիրներ (Regression problems)
- Դասակարգման խնդիրներ (Classification problems)

Ռեգրեսիայի խնդրներում փորձում ենք կանխատեսել անընդհատ ֆունկցիայի արժեքներ, ինչը նշանակում է, որ մենք փորձում ենք մուտքային փոփոխականները համապատասխանեցնել ինչ-որ անընդհատ ֆունկցիայի ելքային արժեքներին: Դասակարգման հարցում մենք փոխարենը փորձում ենք կանխատեսել ընդհատ ելքային արժեքներ: Այլ կերպ ասած, մենք փորձում ենք մուտքային փոփոխականները համապատասխանեցնել դիսկրետ կատեգորիաների:

Ռեգրեսիայի խնդրի օրինակ՝ «Տրված մարդու նկարից որոշել նրա տարիքը»:

Դասակարգման խնդրի օրինակ՝ «Տրված է որևէ հիվանդի ուռուցքի մասին ինֆորմացիա, որոշել արդյո՞ք ուռուցքը չարորակ է, թե՞ բարորակ»:

### 1.1.2 Չվերահսկվող ուսուցում

Չվերահսկվող ուսուցումը (Unsupervised Learning) հնարավորություն է տալիս լուծել այնպիսի խնդիրներ, որոնց ելքային արժեքների մասին կա՛մ քիչ ինֆորմացիա ունենք, կա՛մ ընդհանրապես չգիտենք, թե ինչ տեսքի պետք է լինեն: Մենք կարող ենք ստանալ մի այնպիսի ելքային տվյալի կառուցվածք, որի վրա մուտքային տվյալի ազդեցությունն անգամ չգիտենք: Այդ կառուցվածքը հնարավոր է ստանալ տվյալները համախմբելու արդյունքում՝ հիմնված մուտքային տվյալի փոփոխականների միջև կապերի վրա:

Չվերահսկվող ուսուցման ժամանակ կանխատեսման արդյունքների վրա հիմնված հետադարձ կապ չկա: Այսինքն մոդելը չի փոփոխում իր պարամետրերը՝ հիմնվելով կանխատեսման արդյունքների վրա:

Օրինակներ՝

Կլաստերիզացիա. վերցնել 1,000,000 տարբեր գեների հավաքածու և ավտոմատացնել այդ գեների խմբավորումն այնպիսի խմբերում, որոնք ինչ-որ կերպ նման են կամ կապված են տարբեր փոփոխականների հետ՝ ինչպիսիք են կյանքի տևողությունը, գտնվելու վայրը, դերը և այլն:

Ոչ կրաստերիզացիա. «Կոկտեյլային երեկույթի ալգորիթմը», թույլ է տալիս գտնել կառուցվածք քառասային միջավայրում (այսինքն, առանձնացնել մարդու խոսակցության ձայնը երեկույթում հնչող երաժշտությունից):

### 1.1.3 Որոշ նշանակումներ

Կատարենք մի քանի նշանակումներ, որոնք կոգտագործվեն հետագայում:

Դիցուք ունենք հետևյալ տվյալները՝

$X_1$	...	$X_n$	$Y$
$Input^{(1)}_1$	...	$Input^{(1)}_n$	$Output^{(1)}$
...	...	...	...
$Input^{(m)}_1$	...	$Input^{(m)}_n$	$Output^{(m)}$

$X_1, X_2, \dots, X_n$ -ը մուտքային պարամետրերի նշանակումներն են,  $Y$ -ը՝ ելքային պարամետրի նշանակումը:  $Input^{(i)}_1, Input^{(i)}_2, \dots, Input^{(i)}_n$ -ը մուտքային պարամետրերի արժեքներն են (տվյալի հատկություններ), իսկ  $Output^{(i)}$ -ն՝ ելքային պարամետրի արժեքն է, որտեղ՝  $i=1,2,\dots,m$ : Հարմարավետության համար  $Input^{(i)}_1, Input^{(i)}_2, \dots, Input^{(i)}_n$ -ը նշանակենք  $x^{(i)}$ -ով, իսկ  $Output^{(i)}$ -ն՝  $y^{(i)}$ -ով: Պարզ է, որ՝  $n$ -ը մուտքային պարամետրերի քանակն է:

$(x^{(i)}, y^{(i)})$  զույգն անվանում ենք ուսուցման օրինակ (training example), իսկ դրանց ցուցակը՝ ուսուցման տվյալներ (training set): Այսինքն  $m$ -ը՝ ուսուցման տվյալների քանակն է:

Այժմ կարող ենք տալ վերահսկվող ուսուցման ավելի ֆորմալ ձևակերպում՝ «Վերահսկվող ուսուցման նպատակն է՝ տրված ուսուցման տվյալների հիման վրա ձևավորել մի այնպիսի  $h: X \rightarrow Y$  ֆունկցիա, որ  $h(x)$ -ի ելքային արժեքը բավարար մոտ լինի համապատասխան  $y$ -ի արժեքին»:  $h$  ֆունկցիան անվանում են «հիպոթեզ»:

Ինչքան  $h(x)$ -ի արժեքը մոտ լինի համապատասխան  $y$ -ի արժեքին, այնքան ավելի ճիշտ արդյունքներ կտա մեր մեքենայական ուսուցման մոդելը:

Բնականաբար  $h(x)$ -ը ունի գործակիցներ, նշանակենք այդ գործակիցները  $\theta_0, \theta_1, \dots, \theta_n$ -ով, այս պատճառով  $h(x)$  - ը որոշ դեպքերում կնշանակենք  $h_\theta(x)$  :

Հասկանալի է, որ մեր խնդիրը հենց այդ  $\theta$  - ների արժեքները գտնելու մեջ է կայանում, քանզի հետագայում՝ երբ արդեն մեր մոդելը բավարար չափով ուսուցանված կլինի, և ունակ կլինի գուշակել ճիշտ արժեքներ, նրան տրվելու են  $X_1, X_2, \dots, X_n$  արժեքները և քանզի այն ունի արդեն հաշվարկված  $\theta_0, \theta_1, \dots, \theta_n$  արժեքները, ընդամենը պետք է հաշվի  $h_\theta(x)$  - ի արժեքը:

## 1.2 Ուսուցման տարրեր

### 1.2.1 Արժեքի ֆունկցիա

$h(x)$ -ի արժեքների ճշտությունը կարելի է գնահատել **արժեքի ֆունկցիայի (Cost Function)** միջոցով: Այն իրենից ներկայացնում է  $h(x)$ -ի բոլոր ելքային արժեքների և իրական  $y$ -ների արժեքների միջինացված տարբերություն:

Բանաձևը ներկայացված է ստորև.

$$J(\theta_0, \theta_1, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h(x_i) - y_i)^2$$

Ավելի պարզ այն կարող ենք գրել հետևյալ կերպ՝  $\frac{1}{2} \bar{x}$ , որտեղ  $\bar{x}$ -ը  $(h_\theta(x_i) - y_i)$ -ի քառակուսային միջինն է, այսինքն՝ գուշակված և իրական արժեքի տարբերությունը:

Այս ֆունկցիան նաև կոչվում է քառակուսային սխալի ֆունկցիա (Squared error function): Քառակուսային միջինը բաժանվել է 2-ի՝ հետագա հաշվարկների հարմարավետության համար, քանի որ դրա միջոցով  $(h_\theta(x_i) - y_i)^2$ -ի ածանցումից ստացված 2 բազմապատիկը կվերանա:

Ստացվեց, որ մեր խնդիրը կայանում է  $J(\theta_0, \theta_1, \dots, \theta_n)$  - ը մինիմիզացնելու մեջ, որն ավելի ֆորմալ կարող ենք ներկայացնել հետևյալ կերպ՝


$$\underset{\theta_0, \theta_1, \dots, \theta_n}{\text{minimize}} J(\theta_0, \theta_1, \dots, \theta_n)$$



## 1.2.2 Նվազող գրադիենտ

Այսիպսով արդեն պարզաբանվեց, թե ինչ է հիպոթեզ ֆունկցիան և թե ինչպես կարելի է չափել նրա ճշտությունը: Այժմ անհրաժեշտ է որոշել հիպոթեզի պարամետրերը:

Դիտարկենք հիպոթեզ ֆունկցիայի պարզեցված օրինակ, որն ունի ընդհամենը 2 պարամետր՝  $\theta_0$  և  $\theta_1$ : Պատկերենք այդպիսի հիպոթեզի արժեքի ֆունկցիայի օրինակ (Նկ. 1):



Նկ. 1 2 պարամետրով հիպոթեզի ֆունկցիայի օրինակ

Այստեղ պետք է հստակ պատկերացնել, որ մենք չենք գծում հիպոթեզի գրաֆիկը, այլ փոխարենը գծում ենք նրա **արժեքի ֆունկցիայի** գրաֆիկը, որը ցույց է տալիս, թե  $\theta_0$ -ի և  $\theta_1$ -ի արժեքների համար ինչքանով է հիպոթեզը շեղված սպասվելիք արժեքներից: Հասկանալի է, որ պետք է գտնել տվյալ գրաֆիկի վրայի ամենացածր կետը, որի  $\theta_0$  և  $\theta_1$  արժեքներն էլ հենց կլինեն մեր հիպոթեզի որոնելի պարամետրերի արժեքները (վերևի նկարում կարմիր սլաքներով նշված են տվյալ գրաֆիկի մինիմումները): Քանզի արժեքի ֆունկցիան հիմնականում իրենից ներկայացնում է բարդ մաթեմատիկական բանաձև, այն դժվար է գծել, կամ գտնել, թե  $\theta$ -ի որ արժեքների դեպքում է այն ընդունում մինիմալ արժեք: Հենց այս խնդիրը լուծելու համար օգտագործվում է նվազող գրադիենտը (Gradient Descent):

Նշվածն իրականացնելու համար կօգտագործենք արժեքի ֆունկցիայի ածանցյալը: Ածանցյալը ցույց է տալիս տվյալ կետում շոշափողի ուղղությունը, ինչն էլ ինֆորմացիա է

տալիս այն մասին, թե որ ուղղությամբ պետք է շարժվել: Ամեն քայլին շարժվում ենք այն ուղղությամբ, որն ամենաշատն է նվազեցնում արժեքի ֆունկցիան:

Յուրաքանչյուր քայլի չափը որոշվում է  $\alpha$  պարամետրի միջոցով, որը կոչվում է ուսուցման գործակից (learning rate): Օրինակ, վերը նշված գրաֆիկում յուրաքանչյուր «աստղի» հեռավորությունը ներկայացնում է քայլի հեռավորությունը՝ պայմանավորված  $\alpha$  պարամետրով: Փոքր  $\alpha$ -ն համապատասխանում է փոքր քայլի, իսկ մեծը՝ մեծ քայլի: Քայլի ուղղությունը, որոշվում է  $J(\theta_0, \theta_1)$ -ի մասնակի ածանցյալով: Կախված այն բանից, թե որտեղից ենք սկսում դիտարկել գրաֆիկը, հնարավոր է տարբեր մինիմումների հասնել: Վերևում պատկերված են երկու տարբեր սկզբնակետեր (վերցված են կարմիր շրջանագծերի մեջ), որոնք հասնում են երկու տարբեր մինիմումների:

Ընդհանուր դեպքի համար նվազող գրադիենտի ալգորիթնը կլինի. կրկնել հենյալը մինչև զուգամիտում՝  $\theta_j := \theta_j - \alpha \frac{\delta}{\delta \theta_j} J(\theta_0, \theta_1, \dots, \theta_n)$  որտեղ՝  $j = 0, 1, \dots, n$  ներկայացնում է հատկության հերթական համարը: Այն անվանում են նաև թարմացման կանոն (update rule): Մեր օրինակի համար՝  $n = 1$ :

Յուրաքանչյուր իտերացիային պետք է միաժամանակ թարմացնել բոլոր  $\theta_0, \theta_1, \dots, \theta_n$  պարամետրերը: Այսինքն նախ տվյալ իտերացիայի համար հաշվարկել բոլոր  $\theta$ -ների արժեքները՝  $\theta'$ , որից հետո  $\theta$ -ին վերագրել  $\theta'$ : Եթե կամայական  $\theta_j$ -ի արժեքը թարմացնենք նախքան բոլոր  $\theta$ -ների արժեքները հաշվարկելը, ապա կստանանք սխալ պատասխան:

Պետք է հաշվի առնել, որ կարևոր է  $\alpha$ -ի ճիշտ ընտրությունը, քանզի դրանով է պայմանավորված ալգորիթմի զուգամիտման ժամանակը: Եթե ալգորիթնը չի զուգամիտում կամ շատ ժամանակ է պահանջում մինիմումին հասնելու համար ապա  $\alpha$  քայլաչափը սխալ է ընտրված:

Այստեղ կարող է հարց առաջանալ, թե արդյո՞ք հնարավոր է հասնել մինիմումի՝  $\alpha$ -ի անփոփոխ արժեքի դեպքում: Պատասխանը պարզ է դառնում, երբ հաշվի ենք առնում այն հանգամանքը, որ, քանզի ամեն քայլ անելուց մենք ավելի ենք իջնում արժեքի ֆունկցիայի մակերևույթով ներքև, հետևաբար ամեն քայլի հետ մեկտեղ ածանցյալի արժեքը նվազում է: Իսկ դա նշանակում է, որ անգամ, եթե  $\alpha$ -ն հաստատուն պահենք, այնուամենայնիվ

$\alpha \frac{\delta}{\delta \theta_j} J(\theta_0, \theta_1, \dots, \theta_n)$  արտադրյալը ամեն քայլին կնվազի և հասնելով որևէ մինիմումի այն կհավասարվի  $\theta$ -ի (իրականում  $\theta$ -ի չի հավասարվում, այլ մոտենում է ինչ-որ շատ փոքր թվի, որը մեր խնդրի համար համարվում է բավարար) և հետագա քայլերը ոչ մի կերպով չեն ազդի  $\theta$ -ների արժեքների վրա:

Հետևությանը կարելի է համոզվել, որ, եթե մեր հիպոթեզն ունի գծային տեսք՝

$$h_{\theta}(x) = \theta_0 + \theta_1 X_1 + \theta_2 X_2 + \dots + \theta_n X_n$$

ապա թարմացման կանոնի մեջ  $J(\theta)$ -ի արժեքը տեղադրելուց հետո թարմացման կանոնի տեսքը կլինի՝

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$$

որտեղ՝  $j:=0 \dots n$ :

Այստեղ և հետագայում կընդունենք, որ  $x_0^{(i)} = 1$ , բոլոր  $i$ -երի համար: Սա արվում է բանաձևերը հարմար ներկայացնելու համար: Ստացվեց, որ գծային հիպոթեզն ունի հետևյալ տեսքը՝

$$h_{\theta}(x) = \theta_0 X_0 + \theta_1 X_1 + \theta_2 X_2 + \dots + \theta_n X_n$$

### 1.2.3 Ուսուցման գործակից

Նվազող գրադիենտն իրականացնելուց հետո անհրաժեշտ է հետևել ալգորիթմի աշխատանքին (մոդելի ուսուցման պրոցեսին) և հասկանալ արդյո՞ք այն ճիշտ է աշխատում:

Պատկերացում կազմելու համար, թե ինչքան լավ է սովորում մոդելը, անհրաժեշտ է գծել արժեքի ֆունկցիայի՝  $J(\theta)$ -ի, կախումը *խտերացիաների քանակից*: Պարզ է, որ, եթե ամեն ինչ ճիշտ է աշխատում, ապա ամեն խտերացիայից հետո  $J(\theta)$ -ի արժեքը պետք է նվազի՝ ձգտելով  $\theta$ -ի: Հետևաբար, եթե գրաֆիկը աճում է, ապա ինչ որ բան այն չէ: Հիմնականում դրա պատճառը  $\alpha$ -ի մեծ արժեքն է լինում. անհաժեշտ է նվազեցնել  $\alpha$ -ի արժեքը:

Հարկ է նշել՝ ապացուցված է, որ, եթե ուսուցման գործակից (Learning Rate)  $\alpha$ -ն բավարար չափով փոքր է ընտրված, ապա  $J(\theta)$ -ն նվազում է ամեն իտերացիային: Սակայն, եթե այն շատ փոքր է ընտրված, ապա  $J(\theta)$ -ն կարող է շատ դանդաղ նվազել:

Կարելի է համարել որ մոդելը բավարար չափով ուսուցանվել է այն պահին, երբ  $J(\theta)$ -ի փոփոխությունն ինչ-որ իտերացիայից հետո ավելի փոքր է որևէ  $E$  արժեքից:  $E$ -ն կամայապես ընտրված փոքր թիվ է, օրինակ՝  $10^{-3}$ : Գործնականում դժվար է ընտրել  $E$ -ի օպտիմալ արժեք:

#### 1.2.4 Մուտքային տվյալի հատկության մասշտաբավորում

Մենք կարող ենք արագացնել նվազող գրադիենտի աշխատանքը՝ բերելով բոլոր մուտքային պարամետրերը մոտավորապես նույն տիրույթի թվերի: Դա կապված է այն բանի հետ, որ որ  $\theta$ -ն ավելի արագ է հասնում մինիմումին փոքր միջակայքերում և ավելի դանդաղ՝ մեծ միջակայքերում, հետևաբար այն տատանվելով է այն տատանվելով է ձգտում մինիմումին, երբ փոփոխականները շատ անհավասար են:

Դա կանխելու համար կարող ենք այնպես փոփոխել հատկությունները (մուտքային պարամետրերը), որ նրանք ընկնեն մոտավորապես միևնույն թվային տիրույթ: Իդեալական դեպքում՝

$$-1 < x_i < 1$$

կամ՝

$$-0.5 < x_i < 0.5$$

Մրանք պարտադիր պահանջներ չեն, մենք ընդամենը փորձում ենք կրճատել հաշվարկների ժամանակը: Նպատակն է՝ բերել բոլոր մուտքային փոփոխականները միևնույն տիրույթի:

Հարկ է նշել նաև, որ, եթե չկատարվի հատկությունների մասշտաբավորում, ապա որոշ դեպքերում հնարավոր է, որ ալգորիթմը երբեք չգուգամիտի:

Հատկության մասշտաբավորումն<sup>[10]</sup> (Feature Scaling) ու միջինով նորմալացումը (mean normalization) այն երկու մեթոդներն են, որոնք կօգնեն լուծել այդ խնդիրը: Առաջինը

ենթադրում է մուտքային տվյալների բաժանում նրանց մեծագույն և փոքրագույն արժեքների տարբերության վրա: Միջինով նորմալացման դեպքում պետք է մուտքային փոփոխականից հանել մուտքային տվյալների միջին արժեքը, ապա նոր բաժանել մեծագույն և փոքրագույն արժեքների տարբերության վրա: Ստացվեց, որ այս երկու մեթոդների իրականացման համար անհրաժեշտ է փոփոխել մուտքային պարամետրերը՝ համապատասխան ներքևի բանաձևի:

$$x_i := \frac{x_i - \mu_i}{s_i}$$

որտեղ  $s_i$ -ն  $i$ -րդ հատկության մեծագույն և փոքրագույն արժեքների տարբերությունն է, իսկ  $\mu_i$ -ն՝ այդ հատկության բոլոր արժեքների միջինը: Նշենք, որ  $s_i$ -ին կարող ենք ընդունել հավասար միջին քառակուսային շեղմանը, և այդ դեպքում ստացված արժեքները կտարբերվեն նախորդ տարբերակով ստացված արժեքներից:

Նշվածի օրինակ կարող է ծառայել հետևյալը՝ եթե  $x_i$ -ն ներկայացնում է բնակելի տան բարձրություն, և գտնվում է 4-ից 34 միջակայքում, իսկ այդ հատկության բոլոր արժեքների միջինը հավասար է 18-ի, ապա  $x_i := \frac{\text{արժեք}-18}{30}$ :

### 1.3 Պոլինոմալ ռեգրեսիա

Բնականաբար հիպոթեզ ֆունկցիան կարող է լինել կամայական տեսակի: Նրա տեսքը պարզելու համար անհրաժեշտ է կատարել տվյալների ուսումնասիրություն: Եթե ուսումնասիրությունից հետո պարզվում է, որ հիպոթեզը չպետք է լինի գծային, ապա կարևոր է իմանալ, որ հնարավոր է ձևափոխել այն քառակուսայինի, խորանարդայինի կամ այլ տեսքի կորի:

Օրինակ, եթե մեր հիպոթեզ ֆունկցիան ունի հետևյալ տեսքի՝

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1$$

ապա կարելի է ստեղծել նոր հատկություններ՝ հիմնված  $x_1$ -ի վրա այնպես, որ ստանանք քառակուսային ֆունկցիա՝

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_1^2$$

կամ խորանարդային ֆունկցիա՝

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^3$$

Այս օրինակներում ստեղծեցինք նոր՝  $x_2$  և  $x_3$ , հատկություններ, որտեղ  $x_2 = x_1^2$ , իսկ  $x_3 = x_1^3$ :

Այն քառակուսի արմատի տեքի դարձնելու համար, կարելի է կատարել հետևյալ ձևափոխությունը՝

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 \sqrt{x_1}$$

Նշված ոչ գծային հիպոթեզները պոլինոմալ ռեգրեսսիայի (Polynomial Regression) օրինակներ են:

Շատ կարևոր է հիշել, որ նշված կերպով հատկություններ ավելացնելիս շատ կարևոր է կատարել հատկությունների մաշտաբավորում, քանի որ հատկությունների տիրույթներն իրարից խիստ տարբերվելու են:

Օրինակ, եթե  $x_1$ -ը 1-1,000 տիրույթում է, ապա  $x_1^2$ -ն կլինի 1-1,000,000, իսկ  $x_1^3$ -ը՝ 1-1,000,000,000:

## 1.4 Ղասակարգում

Որպես ղասակարգման խնդիր լուծելու մեթոդ կարելի է օգտագործել գծային ռեգրեսսիան և 0.5-ից մեծ գուշակված արժեքներն ընդունել որպես 1, իսկ դրանից փոքրերը՝ 0: Սակայն այս մեթոդը լավ չի աշխատում, քանի որ ղասակարգուման հիպոթեզն իրականում գծային ֆունկցիա չէ: Այն ռեգրեսսիայի խնդիր է, սկայան այն տարբերությամբ, որ նրա արժեքները վերջավոր քանակի դիսկրետ արժեքներ են:

Մինչ ավելի բարդ դեպքերի անցնելը, կենտրոնանաք երկուական ղասակարգման խնդրի (binary classification problem) վրա, որտեղ  $y$ -ը կարող է ընդունել միայն 2 արժեք՝ 0 և 1: Օրինակ, եթե պետք է ստեղծել սպամ-նամակների գտնող մոդել, ապա նրա մուտքին տրված ամեն մի նամակի  $x^{(i)}$  հատկությունների համար ելքը կարող է լինել 1, եթե այն սպամ է, և 0՝ հակառակ դեպքում:


Դասակարգման խնդրի լուծելու համար կարող ենք անտեսել այն հանգամանքը, սպասվող ելքը վերջավոր, դիսկրետ արժեքներ են և օգտագործենք գծային ռեգրեսիան այս խնդրի լուծման համար: Սակայն այս դեպքում անգամ անհիմաստ են  $h_{\theta}(x)$ -ի 1-ից մեծ և 0-ից փոքր արժեքները, քանի որ մենք գիտենք, որ  $y \in \{0, 1\}$ : Սրան լուծում տալու համար կձևավորենք  $h_{\theta}(x)$ -ն այնպես, որ նա բավարարի  $0 \leq h_{\theta}(x) \leq 1$  պայմանը: Դա անելու համար կարելի է լոգիստիկ ֆունկցիային (Logistic Function) փոխանցել  $\theta^T x$ -ը՝

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Այստեղ  $g$ -ն հենց այն լոգիստիկ ֆունկցիան է, որը կամայական իրական թիվ համապատասխանեցնում է  $(0, 1)$  տիրույթի որևէ թվի, ինչը թույլ է տալիս կամայական տիրույթի ելքային արժեքներ ունեցող ֆունկցիան փոխակերպել դասակարգման խնդրին ավելի հարմար ֆունկցիայի:

Լոգիստիկ ֆունկցիան նաև անվանում են Սիգմոիդ ֆունկցիա (Sigmoid Function):

Նկ. 2-ում պատկերված է այդպիսի ֆունկցիայի մի օրինակ:



Նկ. 2 Սիգմոիդ ֆունկցիայի օրինակ

Այսպիսով  $h_{\theta}(x)$ -ը հավանականությունն է այն բանի, որ ելքային արժեքը հավասար է 1-ի: Օրինակ, եթե  $h_{\theta}(x) = 0.7$ , ապա նշանակում է, որ ելքային արժեքի 1 լինելու հավանականությունը 70% է: Բնականաբար ելքային արժեքի 0 լինելու հավանականությունը հավասար է  $(1 - h_{\theta}(x))$ -ի, այսինքն տվյալ օրինակի դեպքում՝ 30%:

Այս ամենն ավելի ֆորմալ տեսքով կարող ենք գրել այսպես.

$$h_{\theta}(x) = P(y = 1|x; \theta) = 1 - P(y = 0|x; \theta)$$


### 1.4.1 Որոշման սահման

Քանի որ  $h_{\theta}(x)$ -ի արդյունքը  $y=1$  պայմանի հավանականություն է, անհրաժեշտ է ընտրել մի սահման, և ընդունել, որ այդ սահմանից բարձր  $h_{\theta}(x)$ -երի համար  $y=1$ , հակառակ դեպքում  $y=0$ : Օրինակ, եթե համարենք, որ  $y=1$ , երբ  $h_{\theta}(x) > 0.5 \Rightarrow g(\theta^T x) > 0$ , ապա նայելով սիգմոիդ ֆունկցիայի գրաֆիկին, կարող ենք ասել, որ այդ դեպքում  $\theta^T x$ -ը պետք է մեծ լինի  $0$ -ից:

Ասվածն ավելի պարզ հասկանալու համար դիտարկենք հետևյալ օրինակը. դիցուք՝

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

իսկ ուսուցման տվյալները Նկ. 3-ում պատկերված տեսքն ունեն:




Նկ. 3 Ուսուցման տվյալների (training set) օրինակ №1

ինչպես նաև ենթադրենք, թե ուսուցման վերջում ստացել ենք, որ  $\theta_0 = -3$ ,  $\theta_1 = 1$ ,  $\theta_2 = 1$ , կամ մատրիցի տեսքով՝

$$\theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

ապա ստացվում է, որ  $y=1$ , երբ  $-3 + x_1 + x_2 \geq 0$ , պարզագույն ձևափոխություններից հետո ստանում ենք  $x_2 \geq -x_1 + 3$ , ինչն իրենից ուղիղ գծի հավասարում է ներկայացնում: Վերջինիս գրաֆիկը գծված է Նկ. 4-ում՝ կանաչ գույնով:






Նկ. 4 Չժային տեսքի որոշման սահմանի օրինակ

Ստացվեց, որ այս կանաչ գծից վերև բոլոր  $(x_1, x_2)$  զույգի համար՝  $y=1$ : Նույն կերպ նրանից ներքև բոլոր  $(x_1, x_2)$  զույգի համար՝  $y=0$ :

Հենց այս գիծն էլ կոչվում է **որոշման սահման (Decision Boundary)**, քանի որ այն ներկայացնում է մի սահման, որը բաժանում է  $y=1$ -երի խումբը  $y=0$ -երի խմբից:

Դիտարկենք մեկ այլ դեպք:



Նկ. 5 Ուսուցման տվյալների (training set) օրինակ № 2


Նկ. 5-ում պատկերված են ուսուցման տվյալները: Պարզ է, որ այստեղ որոշման սահմանը չունի գծային տեսք: Դիցուք այս կոնկրետ օրինակի համար հիպոթեզն ունի հետևյալ պոլինոմալ ֆունկցիայի տեսքը՝

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

իսկ ուսուցման վերջում ստացվել է՝

$$\theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$$

Հետևաբար ստացվում է, որ  $y=1$ , երբ  $-1 + x_1^2 + x_2^2 \geq 0$ , որտեղից ստանում ենք, որ  $x_1^2 + x_2^2 \geq 1$ , ինչն էլ 1 շառավիղով,  $(0,0)$  կենտրոնով շրջանագծի հավասարումն է: Որոշման սահմանը կունենա Նկ. 6-ում պատկերված տեսքը:



Նկ. 6 Ոչ գծային որոշման սահմանի օրինակ

Գծված շրջանագծից, դուրս բոլոր  $(x_1, x_2)$  գույգերի համար  $y=1$ , իսկ նրա ներսում՝  $y=0$ :

Կախված հիպոթեզ ֆունկցիայի բարդությունից, որոշման սահմանը կարող է լինել տարբեր տեսքի:

#### 1.4.2 Լոգիստիկ հիպոթեզի արժեքի ֆունկցիան


Ընդհանուր դեպքում արժեքի ֆունկցիան ունի հետևյալ տեսքը՝

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x_i), y_i)$$

որտեղ  $\text{Cost}$ -ը այն ֆունկցիան է, որը հաշվում է արժեքը  $i$ -րդ ուսուցման օրինակի համար:

Արդեն նշվել է, որ գծային հիպոթեզի դեպքում  $\text{Cost}(h(x_i), y_i) = (h(x_i), y_i)^2$ , սակայն լոգիստիկ ֆունկցիայի համար չի կարելի օգտագործել նույն բանաձևը, քանի որ այդ կերպ ստացված  $J$  ֆունկցիան ալիքային տեսքի է և հետևաբար ունի բազմաթիվ լոկալ մինիմումներ, որոնք բարդացնում են գլոբալ մինիմումը գտնելը: Այլ կերպ ասած  $J$ -ի գրաֆիկը ուռուցիկ չի լինի:

Ասվածն ավելի լավ պատկերացնելու համար Նկ. 7-ում բերված են ուռուցիկ և ոչ ուռուցիկ ֆունկցիաների գրաֆիկների օրինակներ:





Նկ. 7 Ուռուցիկ և ոչ ուռուցիկ ֆունկցիաների գրաֆիկների օրինակ

Փոխարենը կարելի է օգտագործել հետևյալ ֆունկցիան՝

$$\begin{cases} \text{Cost}(h_{\theta}(x), y) = -\log(h_{\theta}(x)) & \text{երբ } y = 1 \\ \text{Cost}(h_{\theta}(x), y) = -\log(1 - h_{\theta}(x)) & \text{երբ } y = 0 \end{cases}$$

Այս դեպքում ստանում ենք Նկ. 8-ում պատկերված գրաֆիկները:



Նկ. 8 Լոգարիթմական ֆունկցիաների գրաֆիկներ

Այստեղից երևում է, որ, եթե արժեքի ֆունկցիան գրենք այս ձևով, ապա համոզված կարող ենք ասել, որ  $J$ -ն ունի ուռուցիկ տեսք լոգիստիկ ռեգրեսիայի համար: Ինչը շատ կարևոր է ավելի արագ ուսուցանվող և ճիշտ արդյունքներ գուշակող մոդել ստեղծելու համար:

Ելնելով գրաֆիկից կարող ենք ասել.

- Երբ  $y=0$ , ապա արժեքի ֆունկցիան կլինի 0, միայն, եթե հիպոթեզի ֆունկցիայի ելքում նույնպես ստացվի 0: Եթե հիպոթեզը ձգտում է 1-ի, ապա արժեքի ֆունկցիան կձգտի անվերջության:
- Երբ  $y=1$ , ապա արժեքի ֆունկցիան կլինի 0, միայն, եթե հիպոթեզի ֆունկցիայի ելքում նույնպես ստացվի 1: Եթե հիպոթեզը ձգտում է 0-ի, ապա արժեքի ֆունկցիան կձգտի անվերջության:

Ասվածը մաթեմատիկորեն կարող ենք ներկայացնել հետևյալ կերպ՝

- $h_{\theta}(x_i) = y \Rightarrow Cost(h_{\theta}(x_i) y_i) = 0$
- $\begin{cases} y = 0 \\ h_{\theta}(x_i) \rightarrow 1 \end{cases} \Rightarrow Cost(h_{\theta}(x_i) y_i) \rightarrow \infty$
- $\begin{cases} y = 1 \\ h_{\theta}(x_i) \rightarrow 0 \end{cases} \Rightarrow Cost(h_{\theta}(x_i) y_i) \rightarrow \infty$

Լոգիստիկ հիպոթեզի արժեքի ֆունկցիայի համակարգը կարելի է փոխարինել մեկ արտահայտությամբ հետևյալ կերպ՝

$$Cost(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$$

Հետևաբար  $J$ -ն կունենա հետևյալ տեսքը՝

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[ -y^{(i)} \log(h_{\theta}(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

Կատարելով մաթեմատիկական ձևափոխություններ կարելի է համոզվել, որ այս դեպքում թարմացման կանոնը կլինի նույնն ինչ գծային ռեգրեսիայի համար՝

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$$

որտեղ  $j=0, 1, \dots, n$ :

### 1.4.3 Բազմադաս դասակարգում

Դասակարգման խնդիրներ քննարկելիս մինչ այս պահը դիտարկել ենք միայն երկուսական դասակարգիչ, այսինքն հնարավոր էր միայն 2 ելք՝  $y=\{0, 1\}$ : Հիմա կդիտարկենք տվյալների դասակարգումը, երբ առկա են երկուսից ավելի կատեգորիաներ: Վերջինս անվանում են բազմադաս դասակարգում (Multiclass Classification): Այսինքն՝  $y=\{0, 1\}$ -ի փոխարեն ունենք  $y=\{0, 1, \dots, k\}$ :

Քանի որ  $y=\{0, 1, \dots, k\}$ , ապա կրաժանենք խնդիրը  $(k+1)$  երկուսական դասակարգման խնդիրների և ամեն մեկում կգուշակենք, թե ինչքան է հավանականությունն այն բանի, որ  $y$ -ի հերթական խմբի անդամն է՝

$$y \in \{0, 1, \dots, k\}$$

$$h_{\theta}^{(i)}(x) = P(y = i | x; \theta)$$

այստեղ  $i=0, 1, \dots, k$  հերթական կատեգորիայի համարն է, իսկ  $h_{\theta}^{(i)}(x)$ -ը  $y$ -ի  $i$ -րդ կատեգորիայում գտնվելու հավանականությունն է: Հետևաբար գուշակելու համար, թե տրված մուտքային  $x$  օրինակին, ո՞ր կատեգորիան է համապատասխանում, անհրաժեշտ է  $h_{\theta}^{(0)}(x), h_{\theta}^{(1)}(x), \dots, h_{\theta}^{(k)}(x)$ -ից ընտրել մեծագույնը: Սա մաթեմատիկորեն կգրենք այսպես՝

$$\text{գուշակված դասը} = \max(h_{\theta}^{(i)}(x)), \quad i = 0, 1, \dots, k$$

## 1.5 Նորմալ հավասարում

Նվազող գրադիենտը  $J(\theta)$ -ն մինիմիզացնելու տարբերակներից մեկն է: Հիմա կդիտարկենք մեկ այլ տարբերակ, որը հնարավորություն կտա մինիմիզացնել  $J(\theta)$ -ն, առանց որևէ խտրացվող ալգորիթմի: Խոսքը նորմալ հավասարման մասին է, որը հնարավորություն է տալիս գտնել որոնելի  $\theta$ -ների արժեքներն առանց խտրացիայի: Բանաձևը հետևյալն է՝

$$\theta = (X^T X)^{-1} X^T Y$$

որտեղ  $X$ -ը ( $m \times (n+1)$  չափի) ուսուցման տվյալների մատրիցն է,  $Y$ -ը ( $m \times 1$  չափի) ամեն մի ուսուցման օրինակի համապատասխան ելքային արժեքը, իսկ  $X^T$ -ն  $X$ -ի տրանսպոզիցիան է: Այստեղ  $X$ -ը  $m \times (n+1)$  չափի է, քանի որ սկզբնական  $X$  մատրիցին պետք է ավելացնել ամբողջությամբ 1-երով լցված սյունը, որն էլ հենց ամեն ուսուցման տվյալի  $x_0$  արժեքն է:

Հարկ է նշել, որ այս դեպքում պետք չէ կատարել հատկությունների մասշտաբավորում:

Ներքևում բերված է նվազող գրադիենտի և նորմալ հավասարման համեմատության աղյուսակ.

Նվազող գրադիենտ	Նորմալ հավասարում
Պետք է ընտրել $\alpha$	Պետք չէ ընտրել $\alpha$
Անհրաժեշտ է մի քանի խտրացիա	Առանց խտրացիայի
Բարդությունը՝ $O(kn^2)$	Բարդությունը՝ $O(n^3)$
Լավ է աշխատում, երբ $n$ -ը շատ մեծ է	Դանդաղ է, երբ $n$ -ը շատ մեծ է

Նորմալ հավասարումը<sup>[10]</sup> (Normal Equation) մատրիցի հակադարձ, տրանսպոզիցիա և բազմապատկում կատարելու հետ է կապված, այդ պատճառով նրա բարդությունը  $O(n^3)$  է: Այդ պատճառով  $n$ -ի մեծ արժեքների դեպքում այն դանդաղ է աշխատում: Գործնականում, երբ  $n$ -ը գերազանցում է 10,000-ը ավելի լավ է նորմալ հավասարումից անցնել խտրացվող ալգորիթմի:

Հնարավոր է նաև ունենալ այնպիսի մուտքային տվյալների մատրից, որը չունի հակադարձ (անհակադարձելի է): Նշվածի հիմնական պատճառներ կարող են լինել՝

- Ավելորդ հատկությունների առկայությունը, երբ 2 հատկություններ շատ սերտ կապի մեջ են, այսինքն գտնվում են գծային կախվածության մեջ
- Չափից դուրս շատ հատկությունների առկայությունը՝  $m \leq n$ : Այս դեպքում կարելի է հեռացնել որոշ հատկություններ, կամ օգտագործել .կանոնավորումը, որը կմանրամասնենք հետագայում

Նշված խնդիրների լուծումն կարող է լինել որոշ հատկությունների հեռացումը, որոնք գծային կախման մեջ են գտնվում մեկ այլ հատկությունից կամ պարզապես որոշ՝ քիչ կարևոր, հատկությունների հեռացումը, երբ առկա են մեծ քանակի հատկություններ:

## 1.6 Նեյրոնային ցանցեր


Հասկանալու համար, թե ինչ անհրաժեշտություն կա ուսումնասիրել այլ ուսուցման ալգորիթմ՝ նեյրոնային ցանցեր<sup>[11]</sup> (Neural Networks), պատկերացնենք մի դեպք, երբ դասակարգման խնդիր լուծելիս հատկությունները բավարար չեն ճշգրիտ մոդել ուսուցանելու համար, և անհրաժեշտություն է առաջացել ավելացնել նոր՝ քառակուսային, խորանարդային կամ այլ հատկություններ: Այս դեպքում եթե ավելացնենք բոլոր քառակուսային հատկությունները՝

$$\begin{aligned} & x_1^2, x_1x_2, x_1x_3, \dots, x_1x_n \\ & x_2^2, x_2x_3, \dots, x_2x_n \\ & \dots \\ & x_{n-1}^2, x_{n-1}x_n \\ & x_n^2 \end{aligned}$$

ապա կստանանք  $\frac{n \cdot (n+1)}{2} + n$  քանակի հատկություն: Այսինքն ստացվում է, որ նոր հատկությունների քանակը նախկինից մոտավորապես քառակուսային  $\left(\approx \frac{n^2}{2}\right)$  կախում ունի: Նույն ձևով խորանարդային հատկություններ ավելացնելիս կարելի է համոզվել որ կախումը խորանարդային է: Սա կարող է բերել գերհամապատասխանեցման (overfitting) խնդրին ինչպես նաև բավականաչափ մեծ հաշվողական ռեսուրսներ կապահանջվեն նման մեծ թվով հատկությունների հետ աշխատելու համար:

Մեքենայական ուսուցման մեջ օգտագործվող նեյրոնի մոդելը հնարավորինս մոտ է արված մարդու ուղեղի նեյրոնային կառուցվածքին: Յուրաքանչյուր նեյրոն ստանում է

մուտքին որևէ պարամետրեր, կատարում է որոշակի հաշվարկներ, և արդյունների հիման վրա որոշում է թե ինչ ազդանշան ուղարկի հաջորդ նեյրոնին:



Նկ. 9 Նեյրոնի մոդելի օրինակ

Նկ. 9-ում պատկերված է նեյրոնի պարզեցված մոդելը, որն օգտագործվում է մեքենայական ուսուցման մեջ:  $x_1$ ,  $x_2$ ,  $x_3$ -ը մուտքային պարամետրերն են, իսկ դեղինով եզրագծվածը նեյրոնի «մարմինն» է: Այստեղ նույնպես կարող ենք ավելացնել  $x_0 = 1$  պարամետրը, որը կոչվում է շեղում (bias): Նեյրոնի կատարած հաշվարկների արդյունքը հիպոթեզ ֆունկցիայի արժեքն է, որի բանաձևը լոգիստիկ ռեգրեսիայի բանաձևն է: Նեյրոնի հիպոթեզի ֆունկցիան այլ կերպ անվանում են նաև սիգմոիդ ակտիվացման ֆունկցիա: Նեյրոնի ակտիվացիան դա լոկ այն արժեքն է, որը հաշվարկում է այդ նեյրոնը, այլ կերպ ասած նրա ելքում ստացված արժեքն է: Բնականաբար այդ ֆունկցիան, ինչպես և նախորդ մեր դիտարկած սիգմոիդ ֆունկցիան ունի իր պարամետրերը՝  $\theta_0, \theta_1, \dots, \theta_n$  (մեր օրինակի դեպքում  $n = 3$ ), որոնց անվանում են կշիռներ (weights):

Նեյրոնային ցանցը, ինչպես բխում է անունից, բազմաթիվ նեյրոններից բաղկացած ցանց է, որոնց ելքերն ու մուտքերը կապված են միմյանց հետ: Նկ. 10-ում պատկերված է նեյրոնային ցանցի մի պարզ օրինակ:


Ցանցը բաժանվում է շերտերի (layers): Առաջին շերտը անվանում են մուտքային շերտ, քանի որ սա այն շերտն է որտեղ գտնվում են հատկությունները: Վերջին շերտը անվանում են ելքային շերտ, այն հաշվարկում է հիպոթեզ ֆունկցիայի վերջնական արժեքը: Առաջին և վերջին շերտերի միջև ընկաց բոլոր մնացած շերտերն անվանում են թաքնված շերտեր: Վերջիններս թաքնված են, քանի որ ուսուցման ընթացքում նրանց արժեքներին չենք հետևում:  $a_i^{(j)}$ -ով կնշանակված է  $j$ -րդ շերտի  $i$ -րդ նեյրոնի ակտիվացիան, իսկ  $\theta^{(j)}$ -ով կնշանակենք կշիռների այն մատրիցը, որը պարունակում է  $j$ -ից  $(j+1)$  շերտ անցնելու բոլոր



ակտիվացիաների

ֆունկցիաների

պարամետրեր:



Նկ. 10 Նեյրոնային ցանցի պարզ օրինակ

Ընդհանուր դեպքում  $(j+1)$ -րդ շերտի նեյրոնների ակտիվացման ֆունկցիաների տեսքը բերված է ներքևում.

$$a_1^{(j+1)} = g(\theta_{10}^{(j)} x_0 + \theta_{11}^{(j)} x_1 + \dots + \theta_{1n}^{(j)} x_n)$$

$$\vdots$$

$$a_{s_{j+1}}^{(j+1)} = g(\theta_{s_{j+1}0}^{(j)} x_0 + \theta_{s_{j+1}1}^{(j)} x_1 + \dots + \theta_{s_{j+1}n}^{(j)} x_n)$$

որտեղ  $n$ -ը մուտքային պարամետրերի քանակն է, իսկ  $s_{j+1}$ -ը՝  $(j+1)$ -րդ շերտում նեյրոնների քանակը: ց-ֆունկցիան արդեն պարզաբանվել է 1.4 բաժնում: Նշված ֆունկցիաների օգնությամբ վերջին շերտի արժեքը հաշվելով կարող ենք ստանալ  $h_\theta(x)$ -ի արժեքը:

## 1.7 Խնդրի դրվածքը

Ուսումնասիրելով գրականությանը կարելի է եզրահանգել, որ ավարտական աշխատանքի շրջանակներում դրվում է խնդիր՝ մշակել գեներատիվ մրցակցային ցանցերի միջոցով նկարի տեսքով թաքնագրության կրիչ (կոնտեյներ) ստեղծող համակարգ:

Այդ նպատակով անհրաժեշտ է ուսուցանել միաժամանակ 3 մոդել՝ գեներատոր, տարբերակիչ, թաքնավերլուծիչ: Այս մոդելները մրցակցելով միմյանց հետ փորձելու են լավորակել նախագծվող համակարգի արդյունքը, որից հետո համոզվելով, որ մոդելները բավարար չափով ուսուցանված են, գեներացնող մոդելը կկարողանա ստեղծել իրական մարդկանց դեմքերին մոտ այնպիսի նկար-կրիչներ, որոնք կապահովեն բարձր թաքնակայունություն:

2016 թվականին կատարված հետազոտությունները լավ արդյունքներ էին տվել, սակայն գեներացված նկարները մոտ չէին իրական նկարներին: Տվյալ աշխատության մեջ գեներատորին ուսուցանման ժամանակ տրվելու են ինչ-որ հատկանիշներով (սեռ, տարիք, ռասսա) նման մարդկանց նկարներ, ինչը, ենթադրվում է, որ կհանգեցնի իրականին ավելի մոտ նկարների ստեղծմանը:

## Գլուխ 2. Գեներատիվ մրցակցող ցանցերի կիրառումը

### նկարի տեսքով թաքնագրության կրիչ ստեղծելու

#### համար

#### 1.1 Մրցակցող ցանցեր

##### 1.1.1 Մինիմալ խաղ

Մինիմալ խաղը որոշումներ ընդունելու կանոն է, որն օգտագործվում է արհեստական բանականությունության, որոշումների տեսության, խաղերի տեսության, ստատիստիկայի և փիլիսոփայության մեջ, հնարավոր կորուստը (վատագույն դեպքում՝ մաքսիմալ կորուստը) քչացնելու համար: Սկզբում կանոնները նախատեսված էին երկու խաղացողից բաղկացած զրոյական գումարով խաղի համար, որտեղ մի խաղացողի հաղթանակը բացառում է մյուսի հաղթանակը: Հետագայում այն զարգացել է և օգտագործվում է ավելի բարդ խաղերում, ինչպես նաև անորոշության պայմաններում որոշումների ընդունման մեջ:

Խաղացողի մաքսիմալ վատագույն միավորը դա այն ամենամեծ թիվն է, որը խաղացողը կարող է հավաքել, առանց իմանալու հակառակորդների քայլերը: Համապատասխանաբար այդ միավորը այն ամենափոքր թիվն է, որը հակառակորդները կարող են ստիպել խաղացողին հավաքել, երբ գիտեն նրա քայլերը: Ասվածը մաթեմատիկորեն կարող ենք ներկայացնել հետևյալ կերպ՝

$$\underline{v}_i = \max_{a_i} \min_{a_{-i}} v_i(a_i, a_{-i})$$

Որտեղ՝

- $i$ -ն հերթական խաղացողի համարն է
- $-i$ -ն բոլոր խաղացողներն են՝ բացառությամբ  $i$ -րդի
- $a_i$ -ն  $i$ -րդ խաղացողի քայլն է
- $a_{-i}$ -ն բոլոր խաղացողների քայլերն են՝ բացառությամբ  $i$ -րդի
- $v_i$   $i$ -րդ խաղացողի միավորների հաշվման (արժեքի) ֆունկցիան է

i-րդ խաղացողի մաքսիմալ միավորի հաշվարկը կատարվում է հաշվի առնելով վատագույն տարբերակը՝ նրա ամեն մի հնարավոր քայլի համար ստուգվում է մնացած խաղացողների հնարավոր բոլոր քայլերը և գտնվում է վատագույն կոմբինացիան, որը խաղացողին կբերի ամենավերջին միավորը: Հետո պետք է հասկանալ, թե, ինչ քայլ պետք է անի i-րդ խաղացողը, որպեսզի համոզված լինի, որ այս ամենավերջին միավորը դա նրա ամենամեծ հնարավոր միավորն է: Այսինքն i-րդ խաղացողն իր հերթական քայլով մաքսիմիզացնում է իր միավորը և մինիմիզացնում է հակառակորդների ազդեցությունը իր միավորի վրա:

Այն խաղը որում հնարավոր է կիրառել վերը նշված մոտեցումը, անվանում են .Մինիմաքս խաղե:

### **1.1.2 Գեներատիվ մրցակցող ցանցեր**

Մրցակցող ցանցերի առաջին հայտնագործողը Գուդֆելդուն էր: Նա առաջինն էր, ով մտածեց հետևյալ հարցի շուրջ՝ «Ի՞նչ կլինի եթե երկու նեյրոնային ցանցի ստիպենք մրցակցել միմյանց դեմ կամայական տիպի տվյալներ գեներացնելու համար»: Ընդ որում մրցակցող ցանցերից առաջինը տվյալների գեներատորն է, իսկ երկրորդը՝ տարբերակիչը: Այստեղ տվյալ ասելով հասկանում ենք ամեն ինչ՝ նկար, երաժշտություն, վիդեո, տեքստ և այլն: Գեներատորը, ինչպես հետևում է իր անվանումից, տվյալներ գեներացնող մոդելն է, իսկ տարբերակիչը իրական տվյալները գեներացվածներից տարբերակող մոդելն է: Հետագա փորձերի արդյունքները բավականին լավ արդյունքներ ցույց տվեցին և այն, ինչը հայտնաբերեց Գուդֆելդուն կոչվեց «գեներատիվ մրցակցող ցանցեր» (ԳՄՑ): ԳՄՑ-ի միջոցով հնարավոր դարձավ ուսուցանել մի այնպիսի մոդել, որն ունակ է ստեղծել ուսուցման ընթացքում իրեն տրված տիպի տվյալներ: Օրինակ՝ կենդանիների կամ մեքենաների նկարներ: Վերջին տարիներին խորը ուսուցումը (Deep Learning) բավականին առաջընտաց է ապրել: Դրա միջոցով հնարավոր է ստեղծել մոդելներ, որոնք ունակ են ճանաչել տարբեր տեսակի առարկաներ նկարների մեջ, սակայն հնարավոր չէ ստեղծել մի այնպիսի մոդել որը նկարներ կգեներացնի նույնքան լավ, ինչքան ԳՄՑ-երը:


ԳՄՑ-ի միջոցով կարելի է ստանալ հզոր նկարներ գեներատիվ մոդելներ, սակայն ստացված մոդելներն ունակ չեն գեներացնել կամայական տիպի տվյալներ: Այդ մոդելները գեներացնում են միայն այնպիսի տվյալներ, ինչի վրա որ կատարվել է ուսուցումը: Այսպիսով, եթե ԳՄՑ-ի ուսուցման ժամանակ տրվել են միայն շան նկարներ, ապա

գեներատիվ մոդելը կսովորի գեներացնել միայն շան նկարներ, և ունակ չի լինի գեներացնել բոլորովին այլ տիպի կենդանու նկարներ: Իսկ եթե մուտքային տվյալները բավականին տարբեր բնույթի լինեն, ապա հնարավոր է որ գեներատորի ուսուցումը անհաջող լինի և այն վերջիվերջո ունակ չլինի գեներացնել որևէ իմաստ արտահայտող տվյալներ:

Տվյալ աշխատությունում ուսուցման ժամանակ  $G$  գեներատորի մուտքին տրվելու է որևէ  $z$  բաշխումից աղմուկ՝  $p_z(z)$ , որից  $G$ -ն ստանալու է նոր նկար, այդ ֆունկցիան նշանակենք՝  $G(z; \theta_g)$ : Սահմանենք ևս մեկ ֆունկցիա տարբերակիչի համար՝  $D(x; \theta_d)$ , որի ելքը մի սկալար մեծություն է, որն արտահայտում է նրա մուտքին տրված  $x$  նկարի իրական լինելու հավանականությունը: Այսինքն նրա ելքը կլինի 0, եթե մուտքին տրված նկարը գեներացված է, և 1՝ հակառակ դեպքում: Ստացվում է, որ  $D$ -ն մեզ մոտ երկուական դասակարգիչ է: Ուսուցման ընթացքում մենք փորձում ենք մեծացնել  $D$ -ի ճշտությունը, նրա մուտքին տալով իրական և գեներատորի գեներացրած նկարներ: Միևնույն ժամանակ՝ զուգահեռաբար, մենք ուսուցանում ենք  $G$ -ն ստիպելով նրան փոքրացնել  $D$ -ի ճշտությունը: Այլ կերպ ասած այս երկու մոդելները մրցակցում են միմյանց հետ և խաղում են հետևյալ մինիմաքս խաղը  $V(G, D)$  արժեքի ֆունկցիայով՝

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

ԳՄՑ ուսուցանելիս պետք է միշտ հիշել, որ մենք ուսուցանում ենք գեներատորը և տարբերակիչը զուգահեռաբար: Այսինքն ուսուցման մեկ տակտի ընթացքում նեյրոնային ցանցի կշիռները թարմացնում է թե՛ գեներացնող և թե՛ տարբերակող մոդելը: Նկ. 11-ում պատկերված են ուսուցմանը մասնակցող նեյրոնային ցանցերը և նրանց միջև կապերն ու մուտքերը:



Նկ. 11 Գեներատիվ մրցակցող ցանցերի աշխատանքի սխեմա

## 1.2 Խորը փաթույթային գեներատիվ մրցակցող ցանցեր

Ներկա պահին գոյություն ունեն ԳՄՑ-երի տասնյակ տարբեր տեսակներ: Խորը փաթույթային գեներատիվ մրցակցող ցանցերը (ԽՓԳՄՑ) դրանցից մեկն է: ԽՓԳՄՑ-ն նախատեսված է նկարների գեներացիայի համար: Երկար տարիներ ուշադրության կենտրոնում են եղել վերահսկվող փաթույթային նեյրոնային ցանցերը, մինչդեռ ԽՓԳՄՑ-ն լավ օրինակ է չվերահսկվող փաթույթային նեյրոնային ցանցերի ոչ պակաս արդյունավետության: Ինչպես երևում է անվանումից, ԽՓԳՄՑ-երի հիմքում ընկած է փաթույթային ցանցերի գաղափարը, որոշակի փոփոխություններով, որոնք առաջ են քաշվել վերջերս: Դրանք են՝

1. Նեյրոնային ցանցի բոլոր ոչ-փաթույթային՝ միավորման (pooling), շերտերը փոխարինել փաթույթայինով, ինչը հնարավորություն կտա ցանցին սովորել մշակել սեփական downsampling-ը: Այս աշխատությունում այս մոտեցումը օգտագործվել է նաև գեներատորի մոդելավորման համար, ինչը թույլ է տալիս գեներատորին մշակել իր սեփական upsampling-ը:
2. Վերացնել ամբողջությամբ միացված շերտերը փաթույթային շերտերից առաջ:
3. Անհրաժեշտ է կիրառել խմբային նորմալիզացում (Batch Normalization), ինչը կկայունացնի ուսուցումը: Այն կնորմալիզացնի ամեն նեյրոնի մուտքը՝ բերելով միջին արժեքը զրոյի:
4. Տարբերակիչ բոլոր շերտերի համար օգտագործել բացվածքով ReLU (Leaky ReLU) ֆունկցիան ReLU-ի փոխարեն:

## 1.3 Թաքնավերլուծություն մեքենայական ուսուցմամբ

Թաքնագրության ժամանակ կոնտեյներում թաքցվում է գաղտնի տվյալը: Կոնտեյներների դասին են պատկանում նաև նկարները: Նկարներում՝ նրա պիկսելային ներկայացման մեջ ինֆորմացիայի թաքնագրման ժամանակ կատարվում է փոփոխություն նակրի տենզորի մեջ, որը ունի  $N \times M \times C$  չափողականություն, որտեղ՝

1.  $N$ -ը տողերի քանակն է
2.  $M$ -ը սյուների քանակն է
3.  $C$ -ը գույների խորությունն է կամ նկարի հոսքերի թիվը

Հաշվի առնելով այն, որ նկարներում հիմնականում օգտագործվում է 8 բիթ կոդավորում, կարելի է հաշվարկել նկարի տեղագրի չափը բիթերով՝

$$S = N * M * C * 8$$

Նկարի տեղագրի մեջ թաքցվող ինֆորմացիայի քանակը համեմատական է նրա չափին՝

$$T = K_{\text{տրմ}} * S$$

$K_{\text{տրմ}}$  գործակիցը բնութագրում է նկարի կոնտեքստից, որն իր հերթին իրենից ներկայացնում է տեղագրում պիկսելների բաշխման ֆունկցիա:  $K_{\text{տրմ}}$ -ը խիստ կախվածություն ունի պիկսելների բաշխումից և որպես հետևյալնք երկու նույն չափի նկարների թաքնագրման տարողունակությունը կարող է խիստ տարբերվել:  $K_{\text{տրմ}}$ -ն իրենից կրում է զուտ բնութագրական բնույթ և իհարկե հնարավոր է գերազանցել թույլատրելի նորման, սակայն նմանատիպ մոտեցումը կրերի թաքնագրային համակարգի վատթարացմանը և հետագա անվտանգության նվազեցմանը:

Ինչպես արդեն նշվեց  $K_{\text{տրմ}}$ -ը հանդիսանում է ֆունկցիա պիկսելների բաշխումից՝

$$K_{\text{տրմ}} = K(p)$$

Այստեղ  $p$ -ն հանդիսանում է պիկսելների բաշխման ֆունկցիան:  $K$ -ն բավականին դժվար է գնահատել և դժվար է այն ներկայացնել անալիտիկ տեսքով, հաշվի առնելով գոյություն ունեցող նկարների տարատեսակը:

Մեքենայական ուսուցման հիմնախնդիրներից է մոտարկել ֆունկցիան, ըստ մուտքային տվյալների: Այս մոտեցումը խոստումնալից է  $K$ -ի տեսքի որոնման հարցում, քանի որ կարելի է բավականին ճշգրիտ մոտարկել  $K$  ֆունկցիան: Առաջարկվող համակարգում  $K$  ֆունկցիայի մոտարկումը պարամետրիզացվում է նեյրոնային ցանցով:

$$K_{\text{տրմ,մոտ}} = K_w(p_{\text{տվյալ}})$$

Քանզի խնդիրը կայանում է գեներացնել նկարներ մաքսիմալ  $K_{\text{տրմ}}$ -ով, այս աշխատությունում ներկայացվող համակարգում ներդրվում է դասակարգիչ, որի հիմնական նպատակն է հասկանալ արդյոք առկա է նկարում թաքնագրված տվյալ, նույնն է թե արդյոք

գերազանցվել է  $K_{տրմ}$ -ը տվյալ կոնտեյների համար: Քանի որ առաջարկվող մոտեցման մեջ խնդիրը դա մեծ  $K_{տրմ}$ -ով կոնտեյների գեներացումն է, ուսուցման ժամանակ եթե դասակարգիչը հայտանքերում է թաքնագրված տեքստ ապա  $K_{տրմ}$  մոտարկող նեյրոնային ցանցը, որը մոտարկումը կատարում է համապատասխան  $K_{տրմ}$ -ի համար նկարի գեներացմամբ ենթարկվում է պարամետրերի թարմացման ըստ գրադիենտային անկման: Այսպիսի մոտեցումը թույլ է տալիս մաքսիմալացնել գեներացվող կոնտեյներների  $K_{տրմ}$ -ը և որպես հետևանք արդյունքում ստանալ մեծ տարողունակությամբ կոնտեյներ նկարներ:

Թաքնագրված տվյալների դասակարգիչը ուսուցանվում է գեներատորի հետ միասին և ենթարկվում է թարմացման՝ սխալ դասակարգման ժամանակ: Այս մոտեցումը թույլ է տալիս ստանալ տվյալ կոտեքստով նկարների համար բարձր ճշգրտության դասակարգիչ: Այդ դասակարգիչը չի հանդիսանում համապիտանի քանի որ նա կարող է գնահատել միայն ցածր պարամետրիզացիա ունեցող տվյալների բաշխման  $K_{տրմ}$ : Առաջարկվող մոտեցումը սահմանապակում է տվյալների բաշխումը, օգտագործելով միայն մարդկանց դեմքերի սահմանափակ խումբ:

## 1.4 Թաքնագրության կրիչի գեներացիա

Տվյալ աշխատությունում ներկայացված համակարգում իրար են միացված 3 մոդել՝

- G գեներատորի ցանցը, որը գեներացնում է իրականին մոտ նկարներ
- D տարբերակիչը, որը որոշում է արդյո՞ք նկարը իրական է թե գեներացված
- S թաքնավերլուծիչը, որը որոշում է արդյո՞ք նկարը պարունակում է թաքնագրված ինֆորմացիա, թե ոչ

Ընդ որում գեներատորն ու տարբերակիչը իրենցից ներկայացնում են ԽՓԳՄՑ: Այս համակարգի հիմնական տարբերությունը սովորական ԳՄՑ-ներից այն է, որ ուսուցման ընթացքում գեներատորն իր կշիռները թարմացնում է միաժամանակ հիմնվելով երկու մոդելների՝ տարբերակիչի և թաքնավերլուծիչի, արդյունքների վրա: Գեներատորը փորձում է մեծացնել D-ի և S-ի սխալանքը, միևնույն ժամանակ վերջիններս փորձում են քչացնել այն:



Ներքևի հավասարումը վերը նշված օպտիմիզացիայի խնդրի մաթեմատիկական ներկայացումն է, որտեղից երևում է, որ գեներատորը խաղում է մինիմաքս խաղը միաժամանակ D-ի և S-ի հետ՝

$$\alpha \left( \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_{noise}(z)} [\log(1 - D(G(z)))] \right) + \\ + (1 - \alpha) \mathbb{E}_{z \sim p_{noise}(z)} [\log S(\text{Stego}(G(z))) + \log(1 - S(G(z)))] \rightarrow \min_G \max_D \max_S$$

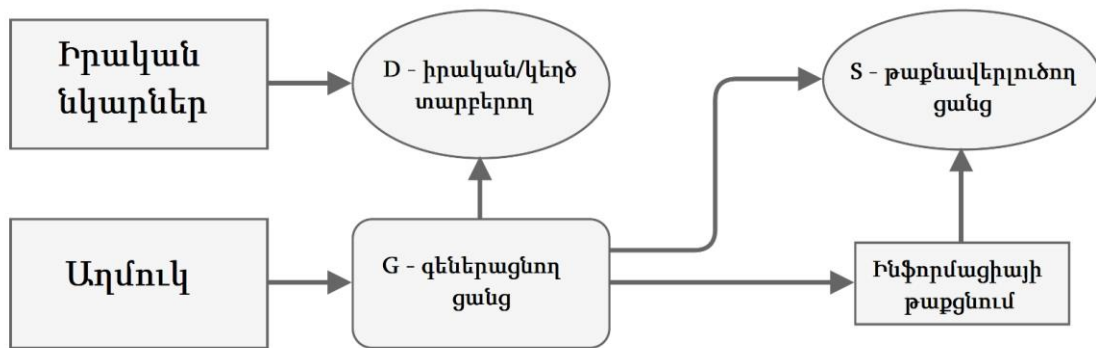
Որտեղ՝

- $p_{data}(x)$ -ը  $x$  բաշխումից ստացված իրական նկարներն են, որի հիման վրա պետք է D-ն սովորի տարբերակել իրական նկարները գեներացվա
- $p_{noise}(z)$ -ը  $z$  բաշխումից ստացված աղմուկն է, որի հիման վրա G-ն պետք է գեներացնի նոր նկարներ
- $\text{Stego}(x)$ -ը մի ֆունկցիա է, որը  $x$  նկարի մեջ կատարում է թաքնագրում և վերադարձնում է արդեն թաքնագրված ինֆորմացիայով նկարը
- $S(x)$ -ը մուտքին տրված  $x$  նկարի թաքնագրված ինֆորմացիա պարունակելու հավանականությունն է

Այս հավասարման մեջ օգտագործվել է D-ի և S-ի սխալանքների գծային գումարը  $\alpha$  պարամետրով, որը որոշում է, թե ինչքանով է կարևոր G-ի գեներացրած նկարի ռեալիզմը թաքնակայուն կրիչ լինելու համեմատ: Այսինքն, եթե  $\alpha$ -ն 1 է ապա մեծ հավանականությամբ գեներացված նկարները կլինեն ռեալիստիկ սակայն չեն լինի թաքնակայուն:

Այսինքն ստացվեց, որ ուսուցման ընթացքում գեներատորի մուտքին տրվելու է կամայական աղմուկ, որից այն գեներացնելու է նկար: Հետո այդ գեներացված նկարը տրվելու է տարբերակիչի մուտքին, որն իր հերթին որոշելու է արդյոք գեներացված նկարն իրական է, թե ոչ: Վերջինիս ուսուցումը վերահսկվող է, քանի որ հայտնի է, որ նկարը գեներացված է: Կախված տարբերակիչի տված արդյունքից իրենց կշիռները թարմացնելու են թե՛ գեներատորը և թե՛ տարբերակիչը: Հետո այդ նույն գեներացված նկարը տրվելու է թաքնավերլուծիչի մուտքին, որն էլ իր հերթին որոշելու է արդյոք կա թաքնագրված

ինֆորմացիա թե ոչ: Թաքնավերլուծիչի ուսուցումը նույնպես վերահսկվող է, քանի որ այս փուլում մենք գիտենք, որ գեներատորի գեներացված նկարում ոչ մի թաքնագրված ինֆորմացիա չկա: Կախված թաքնավերլուծիչի տված արդյունքից վերջինս թարմացնելու է իր ցանցի կշիռները: Այս ամենից հետո նույն նկարի մեջ կատարվելու է թաքնագրում և այն նորից փոխանցվելու է թաքնավերլուծիչին: Այս դեպքում կաղված թաքնավերլուծիչի արդյունքից իրենց ցանցի կշիռներն են թարմացնելու թե՛ գեներատորը և թե՛ թաքնավերլուծիչը: Այս ամենից հետո չպետք է մոռանալ, որ տարբերակիչի մուտքին անհրաժեշտ է փոխանցել իրական նկար և համապատասխանաբար թարմացնել նրա կշիռները: Մոդելները և նրանց միջև վերը նշված կապերը ներկայացված են Նկ. 12-ում



Նկ. 12 Գեներատիվ մրցակցող ցանցի մոդելներն ու նրանց կապերը

2017 թվականին կատարված հետազոտության ժամանակ օգտագործվել է տարբեր տարիքի, սեռի, մաշկի գույնի և այլ տարբեր հատկանիշներ ունեցող, հայտնի մարդկանց նկարներ: Դրա հետևանքով,  $\alpha \leq 0.7$ -ի դեպքում գեներատորի գեներացված նկարները այնքան ոչ-ռեալիստիկ էին ստացվել, որ ընդհանրապես պիտանի չէին: Հետևաբար աշխատության հեղինակները վերցրել էին  $\alpha > 0.7$ , ինչի արդյունքում բնականաբար գեներացված նկարներն ունեցել են ցածր թաքնակայունություն: Տվյալ աշխատությունում նախքան ուսուցումը, մարդկանց նկարները ֆիլտրվելու են, թողնելով միայն սպիտակամորթ տղամարդու նկարներ: Ինչն էլ իր հերթին կբարձրացնի G-ի գեներացված նկարների որակը: Մինչև նույն ժամանակ հնարավոր կլինի  $\alpha$ -ին տալ այնպիսի արժեք՝  $\alpha = 0.5$ , որը զգալիորեն կբարձրացնի նկարների թաքնակայունությունը:

## **Գլուխ 3. Բնապահպանության հարցերի հիմնավորում**

### **1.1 Էկոլոգիական փորձաքննության նպատակները և խնդիրները**

Բնապահպանական կազմակերպությունների, կոմիտեների և հասարակական կազմակերպությունների գործունեության հիմնական ուղղություններից մեկը Էկոլոգիական փորձաքննությունն է:

Համաձայն Հայաստանի Հանրապետության «Մթնոլորտային օդի պահպանության մասին» «Շրջակա միջավայրի վրա ազդեցության փորձաքննության մասին» օրենքների՝ շրջակա միջավայրի վրա ազդեցության (Էկոլոգիական) փորձաքննությունը պետության կողմից անցկացվող պարտադիր գործունեություն է, որի հիմնական նպատակն է կանխորոշել, կանխարգելել կամ նվազագույնի հասցնել հայեցակարգի ն. նախատեսվող գործունեության վնասակար ազդեցությունը մարդու առողջության, շրջակա միջավայրի, տնտեսական և սոցիալական բնական զարգացման վրա:

Շրջակա միջավայրի վրա ազդեցության փորձաքննությունը ելնում է՝

- մարդու առողջության, բնականոն ապրելու և ստեղծագործելու համար բարենպաստ շրջակա միջավայր ունենալու իրավունքից,
- բնական պաշարների արդյունավետ, համալիր և բանական օգտագործման պահանջներից,
- Էկոլոգիական համակարգերի հավասարակշռության և բնության մեջ գոյություն ունեցող բույսերի և կենդանիների բոլոր տեսակների պահպանման անհրաժեշտությունից՝ նկատի ունենալով ներկա և ապագա սերունդների շահերը:
- Էկոլոգիական փորձաքննությունը հատուկ ստեղծված մարմինների, խմբերի առանձին փորձագետների փորձաքննական գործունեության տեսակ է՝ հիմնված փորձաքննման օբյեկտի միջառարկայական՝ էկոլոգա-տնտեսական-

սոցիալական հետազոտման, ստուգման և գնահատման վրա, նպատակ ունենալով դրա իրականացման մասին որոշման կայացումը այն անձի կողմից, ով իրավասու է կայացնելու այդպիսի որոշում: Պետք է նկատի ունենալ, որ Հայաստանի Հանրապետությունում իրականացվում է ինչպես պետական, այնպես էլ հասարակական էկոլոգիական փորձաքննություն:

Պետական էկոլոգիական փորձաքննությունը կանխարգելող հսկողության կազմակերպական իրավական ձև է: Միաժամանակ, այն դուրս է գալիս հսկողությունե հասկացության սահմաններից՝ հանդիսանալով կառավարչական գործունեության ինքնուրույն տեսակ: Պետական էկոլոգիական փորձաքննությունը պետական մարմինների և փորձաքննության հանձնախմբի հատուկ համալիր գործունեություն է: Պետական էկոլոգիական փորձաքննության նպատակը շրջակա բնական միջավայրի պաշտպանության և էկոլոգիական անվտանգության պահանջներին փորձաքննության օբյեկտների համապատասխանությունը ստուգելը և գնահատելն է:

Պետական էկոլոգիական փորձաքննության սկզբունքներն ամրագրված են օրենսդրորեն և նախատեսում են առաջին հերթին՝ փորձաքննության պարտադիր անցկացումը: Պետական էկոլոգիական փորձաքննությունը պետք է նախորդի տնտեսական որոշման կայացմանը՝ նպատակ ունենալով կանխարգելելու շրջակա միջավայրի վրա հնարավոր վնասակար ազդեցությունը: Էկոլոգիական փորձաքննության անցկացումը պարտադիր է բոլոր նախագծերի և ծրագրերի համար: Որպես պարտադիր պետական էկոլոգիական փորձաքննության երաշխավոր նախատեսվում է այն հանգամանքը, որ նախագծերի և ծրագրերի աշխատանքների ֆինանսավորումը հնարավոր է միայն փորձաքննության դրական եզրակացության առկայության դեպքում: Էկոլոգիական փորձաքննությունը հանդես է գալիս որպես շրջակա բնական միջավայրի պահպանության մեխանիզմի գործելու երաշխավոր:

Պետական էկոլոգիական փորձաքննության եզրակացությունների գիտական հիմնավորվածության և օրինականության սկզբունքն արտացոլում է դրա երկու ուղղությունները - գիտական և վարչաիրավական:

Փորձաքննությունը գիտահետազոտական գործընթաց է, հետևաբար, այն պետք է իրականացվի ժամանակակից գիտա-տեխնիկական մակարդակով, գիտական

հետազոտությունների նոր ձևերի և մեթոդների օգտագործմամբ, որակյալ գիտնական-փորձագետների ընդգրկմամբ: Աշխատանքի արդյունքը պետք է լինի ոչ միայն թույլ տրված էկոլոգիական նորմատիվների խախտումների արձանագրումը, այլ նաև դրանց հետևանքների գիտականորեն հիմնավորված գնահատումը թերությունների ուղղման և վերացման համար, որոշում կայացնող մարմիններին երաշխավորությունների տրամադրումը՝ ինչպես նաև փորձաքննվող նախագծերի և օբյեկտների ամենաարդյունավետ ձևով իրականացման պայմանների կանխատեսումը:

Պետական էկոլոգիական փորձաքննության անկախության, արտագերատեսչականության սկզբունքը նշանակում է, որ դրա արդյունավետության պարտադիր պայմանը փորձաքննություն կազմակերպող և իրականացնող մարմինների ֆինանսական անկախությունն է, փորձագետների արտահաստիքային կարգավիճակը:

Կազմակերպորեն պետական էկոլոգիական փորձաքննությունը այնպիսի համակարգ է, որի կառուցվածքն ուղղված է պետական էկոլոգիական փորձաքննության արտագերատեսչականության ապահովմանը: Փորձաքննության հանձնախմբերի, խմբերի ղեկավարությունը, ինչպես նաև փորձաքննության անցկացումը իրականացվում են հիմնականում արտահաստիքային փորձագետների կողմից:

Փորձաքննության ֆինանսական անկախությունն ապահովվում է նրանով, որ այն ֆինանսավորվում է Հայաստանի Հանրապետության բյուջեից և այն միջոցների հաշվին, որոնք ստացվում են պատվիրատուներից փորձաքննության անցկացման, այդ թվում՝ փորձաքննության կրկնակի անցկացման համար: Պատվիրատուների թվարկած ֆինանսական միջոցները ծախսվում են բացառապես պետական էկոլոգիական փորձաքննության վրա՝ դրա անցկացման համար կազմված նախահաշվին լիովին համապատասխան: Էկոլոգիական փորձաքննության ոլորտում հատուկ լիազորված պետական մարմինը պատասխանատվություն է կրում այդ միջոցների նպատակային օգտագործման համար:

Օբյեկտի փորձաքննության իրականացման դեպքում դրա անցկացման ընթացքի, ընդունված որոշումների և կառավարման մարմինների կողմից դրանք հաշվի առնելու վերաբերյալ տեղեկատվությունը պետք է հասանելի լինի բնակչության լայն զանգվածների համար: Կազմակերպորեն փորձաքննության վերաբերյալ աշխատանքը պետք է կառուցված լինի այնպես, որ հասարակական կազմակերպությունները և քաղաքացիները

տեղեկություն ստանան և կարողանան որոշում կայացնող մարմիններին ի գիտություն հասցնել իրենց դիրքորոշումը:

Պետական էկոլոգիական փորձաքննության առարկա են հանդիսանում օբյեկտների և միջոցառումների բերաբերյալ բոլոր նյութերը, որոնք նախատեսվում է իրականացնել Հայաստանի Հանրապետության տարածքում: Տարբերակում են պլանային աշխատանքները և նախապլանային փաստաթղթերը: Առաջինին են վերաբրում տնտեսության ճյուղերի զարգացման, շրջակա բնական միջավայրի վիճակի վերաբերյալ և այլ կանխատեսումները, երկրորդին՝ տեղաբաշխման սխեմաները, շրջանների հատակագծման և քաղաքների կառուցապատման սխեմաները և նախագծերը, առանձին բնական ռեսուրսների օգտագործման համալիր փոքր գետերի պահպանության սխեմաները այլն: Փորձաքննության օբյեկտների թվին են դասվում նաև բոլոր մինչնախագծային նյութերը՝ ըստ օբյեկտների և միջոցառումների, որոնք նախատեսվում է իրականացնել Հայաստանի Հանրապետությունում: Մինչնախագծային նյութերը տեխնիկա-տնտեսական հիմնավորումներն (ՏՏՀ) են, շինարարական նախագծման հիմնական դրույթները, շինարարական նախագծման հատուկ պայմանները, նախագծման առաջադրանքները, հարթակի (ուղեգծի) ընտրման նյութերը և այլն: Նախագծային նյութերն տերմինը վերաբերում է նաև օրենսդրական և այլ նորմատիվ իրավական ակտերի նախագծերին, որոնց ամրագրումը կարող է հանգեցնել բնական շրջակա միջավայրի վրա վնասակար ազդեցության:

Թվարկած օբյեկտները ենթակա են պետական էկոլոգիական փորձաքննության՝ անկախ դրանց նախահաշվային արժեքից և պատկանելությունից: Այս ճանապարհով վերացվում են գերատեսչական խոչընդոտները, այսինքն՝ պետական փորձաքննության ենթակա են ինչպես քաղաքացիական, այնպես էլ ռազմական պաշտպանական օբյեկտները:

Էկոլոգիական փորձաքննության օբյեկտներին են վերաբերում բնօգտագործման համար տրված լիցենզիաների էկոլոգիական, ինչպես նաև սերտիֆիկատների էկոլոգիական հիմնավորումները:

Պետական էկոլոգիական փորձաքննության եզրակացությունը փորձաքննող հանձնաժողովի կողմից պատրաստված փաստաթուղթ է, որը բովանդակում է փորձաքննված գործունեության թույլատրելիության և պետական էկոլոգիական փորձաքննության օբյեկտի հնարավոր իրականացման վերաբերյալ հիմնավորված

եզրակացություններ: Այդ փաստաթուղթը պետք է հավանության արժանանա փորձաքննական հանձնաժողովի ցուցակային կազմի որակյալ մեծամասնության կողմից:

Պատրաստված փաստաթուղթը պետական էկոլոգիական փորձաքննության եզրակացության կարգավիճակ ձեռք է բերում էկոլոգիական փորձաքննության ոլորտում հատուկ երաշխավորված պետական մարմնի կողմից հաստատ հետո: Պետական էկոլոգիական փորձաքննության դրական եզրակացությունը իրավաբանական ուժ ունի այն ժամանակահատվածում, որ որոշել է էկոլոգիական փորձաքննության ոլորտում պետական հատուկ երաշխավորված մարմին, ը պետական էկոլոգիական փորձաքննության օբյեկտի ֆինանսավորման իրականացման պարտադիր պայմաններից մեկն է:

Պետական էկոլոգիական փորձաքննության բացասական եզրակացության իրավական հետևանքը պետական էկոլոգիական փորձաքննության օբյեկտի իրականացման արգելումն է: Բացասական եզրակացության դեպքում պատվիհատուին իրավունք է տրվում կրկին անգամ ներկայացնելու նյութերը պետական էկոլոգիական փորձաքննության: Այս դեպքում պարտադիր պայման է բացասական եզրակացությունում նշված դիտողությունների վերացումը: Բացի դրանից, պատվիրատուն իրավունք ունի եզրակացությունը վիճարկելու դատական կարգով:

Հասարակական էկոլոգիական փորձաքննությունը կազմակերպվում և անց է կացվում քաղաքացիների, հասարակական կազմակերպությունների (միավորումների), ինչպես նաև տեղական ինքնակառավարման մարմինների նախաձեռնությամբ: Այդպիսի փորձաքննություն անցկացնում են գիտական կոլեկտիվները, հասարակական միավորումները: Գործնականում խոսքը առավելապես ժամանակավոր կոլեկտիվների, հանձնախմբերի և խմբերի մասին է: Հասարակական միավորումներ ասելով պետք է հասկանալ քաղաքացիների կամավոր միավորումները:

Հասարակական կազմակերպություններն իրավունք ունեն.

- պատվիրատուից ստանալու էկոլոգիական փորձաքննության ենթակա փաստաթղթերը,
- ծանոթանալու նորմատիվ տեխնիկական փաստաթղթերին, որոնցով սահմանվում են պետական էկոլոգիական փորձաքննության անցկացման պահանջները,

- իրենց ներկայացուցիչների միջոցով, որպես դիտորդ, մասնակցելու պետական էկոլոգիական փորձաքննության փորձաքննական հանձնաժողովի նիստերին և դրանցում հասարակական էկոլոգիական փորձաքննության եզրակացության քննարկմանը:

Հասարակական էկոլոգիական փորձաքննություն կազմակերպող հասարակական կազմակերպությունները պարտավոր են տեղեկացնել բնակչությանը դրա սկզբի և արդյունքների վերաբերյալ:

Հասարակական էկոլոգիական փորձաքննության եզրակացությունը կրում է երաշխավորական, տեղեկատվական բնույթ: Սակայն այն դառնում է իրավաբանորեն պարտադիր դրա արդյունքների պետական էկոլոգիական փորձաքննության համապատասխան մարմինների կողմից հաստատվելուց հետո:

Հասարակական փորձաքննական կոլեկտիվների անդամները իրենց փորձաքննական գնահատականների ճշտության, հիմնավորվածության համար պատասխանատվություն են կրում՝ համաձայն Հայաստանի Հանրապետության օրենսդրության:

Չնայած հասարակական և պետական էկոլոգիական փորձաքննության նպատակները համընկնում են, սակայն դրանց խնդիրները տարբեր են: Որպես կանոն, հասարակական փորձաքննությունը անմիջական փորձաքննության խնդիրների հետ միասին նպատակ ունի պետական մարմինների ուշադրությունը սնեռելու կոնկրետ օբյեկտին, էկոլոգիական վտանգավորության վերաբերյալ գիտականորեն հիմնավորված տեղեկատվությունը հասու դարձնելու լայն հասարակայնությանը:



## Գրականություն

1. Steganography An Art of Hiding Data, Shashikala Channalli et al /International Journal on Computer Science and Engineering Vol.1(3), 2009
2. <https://en.wikipedia.org/wiki/Steganalysis>
3. Generative adversarial nets. Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. pp. 2672–2680, 2014.
4. Unsupervised representation learning with deep convolutional generative adversarial networks. Alec Radford, Luke Metz, and Soumith Chintala. arXiv preprint [arXiv:1511.06434](https://arxiv.org/abs/1511.06434), 2015.
5. Generative adversarial networks for image steganography. Denis Volkhonskiy, Boris Borisenko and Evgeny Burnaev
6. <https://en.wikipedia.org/wiki/Minimax>
7. Mehdi Mirza and Simon Osindero. Conditional generative adversarial nets. arXiv preprint [arXiv:1411.1784](https://arxiv.org/abs/1411.1784), 2014.
8. Generative adversarial text to image synthesis. Scott Reed, Zeynep Akata, Xincheng Yan, Lajanugen Logeswaran, Bernt Schiele, and Honglak Lee. arXiv preprint [arXiv:1605.05396](https://arxiv.org/abs/1605.05396), 2016.
9. <https://www.coursera.org/learn/machine-learning/home/week/1>
10. <https://www.coursera.org/learn/machine-learning/home/week/2>
11. <https://www.coursera.org/learn/machine-learning/home/week/4>